# Tópicos Avançados em Aprendizagem de Máquina - Trabalho 1 - Regressão Linear Bayesiana

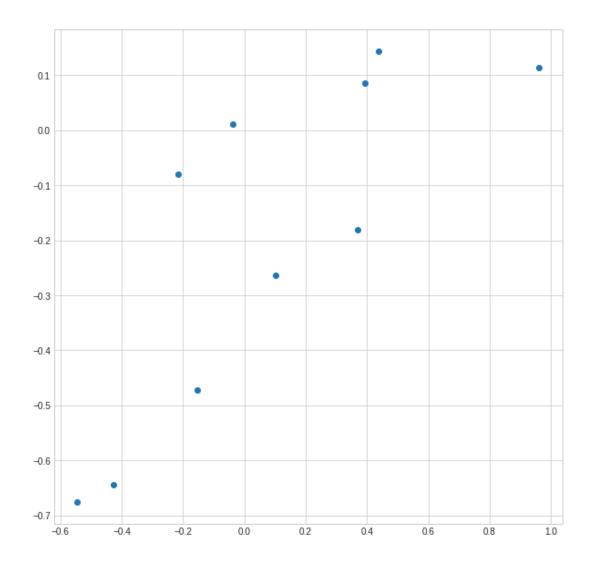
Claudemir Woche Vasconcelos Carvalho 5 de janeiro de 2021

### 1 Importação de bibliotecas

```
[8]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from matplotlib import rcParams
rcParams['figure.figsize'] = (10,10)
plt.style.use("seaborn-whitegrid")
np.set_printoptions(precision=5,suppress=True)
```

# 2 Importação e visualização dos dados

```
[3]: dataset = pd.read_csv('linear_regression_data.csv',header=None).
      →rename(columns={0:'x',1:'y'})
    dataset
[3]:
    0 0.392938 0.086360
    1 -0.427721 -0.643872
    2 -0.546297 -0.674981
    3 0.102630 -0.262892
    4 0.438938 0.143177
    5 -0.153787 -0.472729
    6 0.961528 0.114167
    7 0.369659 -0.180323
    8 -0.038136 0.011821
    9 -0.215765 -0.079865
[4]: plt.scatter(dataset['x'],dataset['y'])
    plt.show()
```



# 3 Pré-processamento dos dados

```
[5]: p = 2
     x = dataset['x'].values.reshape(-1,1)
     y = dataset['y'].values.reshape(-1,1)
     X = np.hstack([np.ones(dataset.shape[0]).reshape(-1,1),dataset['x'].
      \rightarrowvalues.reshape(-1,1)])
     X
[5]: array([[ 1.
                         0.39294],
             [ 1.
                        -0.42772],
             [ 1.
                        -0.5463],
             [ 1.
                         0.10263],
             [ 1.
                         0.43894],
                        -0.15379],
             [ 1.
             [ 1.
                         0.96153],
```

```
[ 1. , 0.36966],
[ 1. , -0.03814],
[ 1. , -0.21576]])
```

### 4 Passo de estimação

#### 4.1 Definições a partir de conhecimentos/experimentos anteriores

Os momentos da priori  $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m_0}, \mathbf{S_0})$ .

$$ightarrow$$
 Definirei  $\mathbf{m_0} = \begin{bmatrix} 0 \ 0 \end{bmatrix}$  e  $\mathbf{S_0} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 

A variância do ruído  $p(\epsilon) = \mathcal{N}(\epsilon|0, \sigma^2)$ 

$$ightarrow$$
 Usarei  $\sigma^2=\{1$  ,  $5e-2$  ,  $1e-2$  ,  $1e-4$  ,  $1e-6$  ,  $1e-8\}$ 

```
[6]: m0 = np.zeros(p).reshape(-1,1)
S0 = np.eye((p))
sigma_ruidos = [1,5E-2,1E-2,1E-4,1E-6,1E-8]
```

#### 4.2 Cálculo da posteriori de w e da distribuição preditiva

Posteriori de w

$$\begin{split} & \rightarrow p(\mathbf{w}|\mathcal{D}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ & \boldsymbol{\mu} = \mathbf{m_0} + (\mathbf{S_0}\mathbf{X}^T\mathbf{X} + \sigma^2\mathbf{I})^{-1} \; \mathbf{S_0}\mathbf{X}^T(\mathbf{y} - \mathbf{X}\mathbf{m_0}) \;, \\ & \boldsymbol{\Sigma} = \mathbf{S_0} - (\mathbf{S_0}\mathbf{X}^T\mathbf{X} + \sigma^2\mathbf{I})^{-1} \; \mathbf{S_0}\mathbf{X}^T\mathbf{X}\mathbf{S_0} \end{split}$$

Distribuição preditiva

$$ightarrow p(\mathbf{y}_*|\mathbf{X}_*) = \mathcal{N}(\mathbf{y}_*|\mathbf{X}_*\boldsymbol{\mu}$$
 ,  $\mathbf{X}_*\mathbf{\Sigma}{\mathbf{X}_*}^T + \sigma^2\mathbf{I})$ 

